

深度集成模型的事故预警方法

石雪怀, 戚湧, 李千目, 张伟斌

(南京理工大学计算机科学与工程学院 江苏南京 210094)

南京理工大学电子工程与光电技术学院 江苏南京 210094)

摘要: 城市火灾作为社会公共安全的重要威胁源, 极易造成巨大经济损失, 甚至导致人员伤亡。城市火灾事故是随机事件, 如何从火灾偶然性的表象出发分析其内部规律是该领域亟待突破的重要问题。本文致力于提供一种端-端框架---基于深度集成模型的事故预警方法, 该方法结合深度神经网络的表示学习能力和树模型的运行效率, 根据不同类型建筑的火灾特点, 使用多个神经网络进行特征学习, 使用一种集成神经网络模型结合特征学习结果进行预测, 并使用一种全局优化方法完成参数优化, 获取最优预测精度。实验表明本方法对火灾事故预警提供了一种较为可行的解决方案, 且在其他任务仍有优秀的表现。

关键词: (深度学习, 集成算法, 事故预警)

中图分类号: TP391

An Accident Warning Approach Based on Deep Stacking

XuehuaiShi¹ Yong Qi¹ Qianmu Li¹ Weibing Zhang²

(1. School of Computer Science and Engineering, Nanjing University of Science and Technology, 210094, China)

(2. School of Electronic & Optical Engineering, Nanjing University of Science and Technology, 210094, China)

【Abstract】 (As an important threat to public security, urban fire accident caused huge economic loss and catastrophic collapse. Predicting and analyzing the interior rule of urban fire accident from its appearance needed to be solved. In this paper, we propose an end-end framework for fire accident warning system based on a deep stacking approach. The method benefits from the representation learning ability of deep neural networks and great serving cost from ensemble models that consists of two layers--- representation learning layer and forest learning layer. Representation learning layer adopts feature learning via multi-NNs based on different types of fire characteristics. Forest learning layer predicts the objective. We achieve the task of optimizing the parameters in representation learning layer and forest learning layer in parallel via a global optimization method. Experiments from fire accident warning system and other different datasets prove the efficacy of the proposed approach.)

【Keywords】 (Deep Learning, Ensemble Model, Accident Warning)

1. 引言

城市火灾事故预警是为了掌握未来火灾事故的状况, 通过对区域火灾事故的历史数据和当前状态数据进行分析, 利用现有数据特征, 分析火灾相关隐私, 对火灾事故未来信息进行预测, 分析火灾事故预警结果, 定制个性化决策从而极大限度避免火灾发生, 减少损失所做出的阐述。

国内外学者基于不同的目标提出了不同的火灾预警系统。如在[1-3]中, 作者从宏观角度, 根据历史火灾数据, 对本年度及下年度火灾进行预测; 在[4]中, 作者基于提供人工神经网络接口的硬件模型建立火灾检测和控制机制, 此硬件模型包含温度感应器、烟雾感应器、火花感应器及微控制器单元, 但没有考虑人为因素及建筑物老化等其他因素对火灾致灾的影响; 在[5]中, 作者依据天气参数及通

到稿日期: 2017-12-27 返修日期: 2017-00-00 本文受国家重点研发计划政府间国际科技创新合作重点专项(2016YFE0108000)资助。

石雪怀 (1995-), 男, 硕士研究生, 主要研究方向: 数据挖掘; 戚湧 (1970-), 男, 博士, 教授, 博士生导师, 通讯作者, CCF高级会员 (E2000228665), 主要研究方向: 数据挖掘, E-mail:790815561@qq.com; 李千目 (1979-), 男, 博士, 教授, 博士生导师, 主要研究方向: 数据挖掘。

过视频监控设备探测烟雾级别作为火灾事故预警信号来建立火灾事故预警模型,此模型评估隐患火灾,提供火灾危险指数,此模型适用于植物群落地区,通过探测烟雾级别作为火灾事故预警信号,适用场景较为局限,此外[6]和[7]致力于森林火灾预测领域,也做出了显著贡献; [8]基于城市 GIS 数据获取地形、人口密度、水道、道路、不合标准的住房和降雨信息使用多准则决策方法建立城市火灾预警系统。由于探测器的缺失,现阶段没有依据建筑物自身特点和建筑物内部动态数据进行相关性分析建立模型的思路,现有火灾事故预警几乎都是宏观的事故率预测,缺少详细可操作的微观事故风险预警。

而计算资源的不断提升,近年来深度神经网络[9,10,11]作为一种新的机器学习方法开始受到研究人员的高度关注。针对大数据,深度学习能够通过底层的特征组合,抽象高层特征来实现数据的分布式表示,从而可以更好地刻画出数据的本质特征。尽管深度神经网络功能强大,其缺点也很明显: 1. 模型训练需要大量数据,对小规模数据不友好; 2. 模型过于复杂,需要大量计算资源; 3. 超参数过多,模型调参困难。而集成学习以其优异的运行效率和模型性能已成功应用于多个领域,如梯度提升树 (GBDT[12])、随机森林 (RF[13]) 等,但由于模型难以表述复杂的非线性关系,也难以获取深度知识对原始数据中优秀的抽象特征进行提取。

本文结合两者优势,提供一种基于深度集成模型的事故预警方法,此方法根据不同类型建筑的火灾特点,使用多个神经网络进行特征学习,使用一种集成神经森林模型结合特征学习结果进行预测,并使用一种全局优化方法完成参数优化,并自适应确定森林模型中树深度。实验表明本方法对火灾事故预警提供了一种较为可行的解决方案,且在其他任务仍有优秀的表现结果。

本文其余部分安排如下:第二章介绍本文要解决的问题,第三章介绍相关工作,第四章详细叙述本文提供方法,第五章将展示本方法在事故预警系统和其他任务中的表现,第六章进行工作总结。

2. 研究现状

在事故预警中,人工的特征提取需要消耗大量资源,深度学习作为一种有效的特征提取工具在学术界和工业界具有广泛的应用,在大数据和计算资源

的支持下 LeNet、FPGAs 取得了卓越的成就,但在事故预警系统中,有标签数据相对不多,难以满足深度学习模型的学习需求。

针对上述问题,国内外研究人员尝试将深度学习与集成模型结合,如 DL Richmond[14]提出一种基于决策森林和卷积神经网络的映射模型,提供一种激励反馈机制,用随机森林为 Cnns 提供更好初始化,更优秀的 Cnns 反作用于随机森林,提升随机森林的表现。P Kotschieder[15]等于 2016 年提出深度神经网络决策森林,此模型将深度学习网络与决策树结合,此方法不同于传统神经网络在于其使用决策森林作出最终预测,不同于传统森林模型的贪婪局部最优的方法寻找分裂节点生成决策树,此模型提出一种规则化的联合全局最优方法优化决策树的节点参数,实验结果表明在 ImageNet 数据集上,此模型结合 GoogLeNet 模型表现优于最新的一些深度学习模型。周志华等[16]于 2017 提出 deep forest,一种决策树集成模型,此方法通过一种级联结构生成深度树模型使模型具有更好的表示学习能力,根据卷积神经网络获得的灵感,针对高维数据提出多粒度扫描法获取数据的上下文及结构信息,实验结果表明此方法具有较少的超参数且对于小规模数据更加友好,针对同量级数据此法模型复杂度相对深度神经网络更低。基于之前的研究成果,集成学习与深度学习的融合成为了一个新的研究热门。

3. 问题描述

本文利用 2011 年至 2017 年深圳市发生火灾的建筑物、当时天气相关数据以及该火灾致灾原因相关数据,建立火灾事故预警系统,数据表头包括 {天气,温度,风级,风向,湿度,建筑物数据特征,标签}。住宅建筑物数据特征如表 1 所示,公共建筑、厂房建筑和仓库建筑特征与住宅建筑有细微差别,主要表现在损失控制因子。根据建筑物不同使用性质,具有不同特征,这些特征用数值描述。标签数据特征为火灾预警等级,包括: 0. 正常无隐患 1. 低度隐患 2. 中度隐患 3. 高度隐患。

因为影响火灾发生的因素非常复杂,除了建筑物自身特性,还有商业地区易燃物聚集以及住宅区电路老化、居民防火意识薄弱等等。现阶段无法针对所有影响火灾发生因素进行分析,且选取数据信息因调研目的不同而有所区别。基于上述原因,本文只选取住宅建筑作为实验数据,对住宅建筑建立

到稿日期: 2017-12-27 返修日期: 2017-00-00 本文受国家重点研发计划政府间国际科技创新合作重点专项(2016YFE0108000)资助。

石雪怀 (1995-), 男, 硕士研究生, 主要研究方向: 数据挖掘; 戚湧 (1970-), 男, 博士, 教授, 博士生导师, 通讯作者, CCF 高级会员 (E2000228665), 主要研究方向: 数据挖掘, E-mail: 790815561@qq.com; 李千目 (1979-), 男, 博士, 教授, 博士生导师, 主要研究方向: 数据挖掘。

火灾事故预警系统，其他三类建筑模型建立方法与 此类似。

表 1. 住宅建筑数据特征

建筑类型	住宅建筑		
致灾因子	燃气方式	人口密度	电气设备安全级别
	内部装修安全级别	建筑物结构	建筑物高度
		屋龄	
损失控制因子	耐火等级	防火隔离级别	安全疏散级别
	安全监控装备级别	室内消火栓装备级别	手提灭火器装备级别

3.1 相关性分析

本文尝试用线性回归模型图的方式指出火灾致灾隐患与各影响要素之间的相关关系，确定火灾致灾隐患与各影响要素之间是否存在一定关系，如图 1 所示。由图 1 可知，风级较大情况相对风级较小时更易产生火灾；从高度与标签线性回归模型图中可看出，一定高度区域中，高度越低，产生火灾可能性相对强，这可能由于较低高度的住宅楼更偏向于屋龄较大的住宅楼，其一些其他致灾因子相对更易产生火灾；从温度与标签的线性回归模型图中可看出，相对高温，较小的处理后温度更易产生火灾，

这令人困惑，但伴随着温度的降低，电气使用率增加等原因会导致火灾的发生；从电气设备安全级别、防火隔离级别、内部装修安全级别、手提灭火器装备级别、建筑物耐火等级、安全监控装备级别、安全疏散级别、室内消火栓装备级别与标签的线性回归模型图中得出其等级越高，越不易发生火灾；从人口密度与标签的线性回归模型图中得出人口密度的增大更易导致火灾，不过其趋势较为平缓；从屋龄与标签的线性回归模型图中得出随着屋龄增加，一定程度上房屋偏于老化时，发生火灾概率增加。

到稿日期：2017-12-27 返修日期：2017-00-00 本文受国家重点研发计划政府间国际科技创新合作重点专项(2016YFE0108000)资助。
石雪怀（1995-），男，硕士研究生，主要研究方向：数据挖掘；戚湧（1970-），男，博士，教授，博士生导师，通讯作者，CCF 高级会员（E2000228665），主要研究方向：数据挖掘，E-mail:790815561@qq.com；李千日（1979-），男，博士，教授，博士生导师，主要研究方向：数据挖掘。

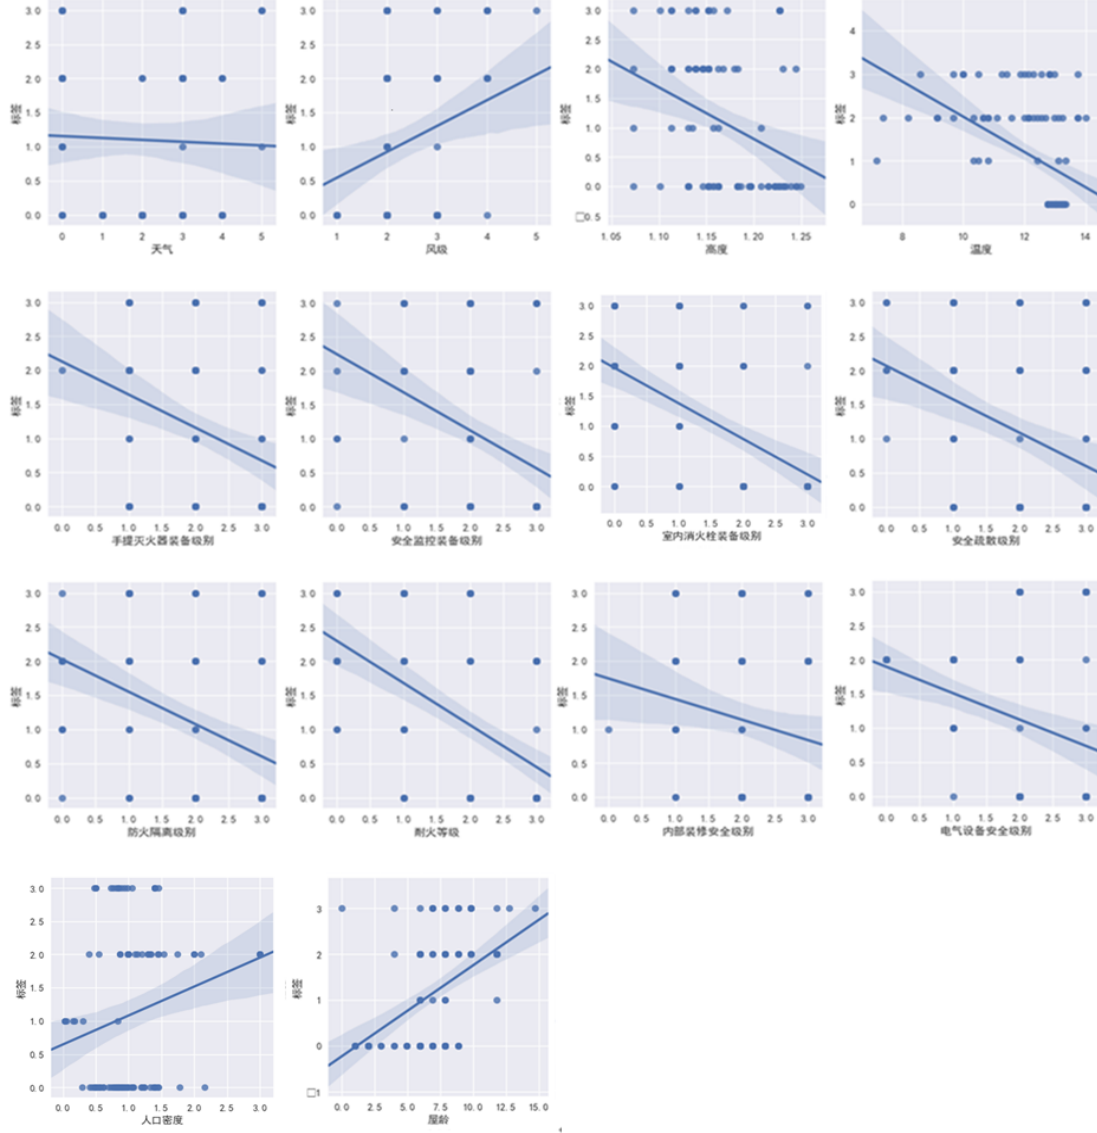


图 1. 不同特征与结果标签对应线性回归模型图

4. 深度集成模型

4.1 总体框架

本文致力于构建一个端-端的深度集成模型来建立火灾事故预警系统, 算法伪代码见算法 1, 总体框架图如图 1 所示。有图 1 可知, 此模型包含两个部分: Representation Learning 层和 Forest Learning 层。假设一个分类问题中, 数据集为 $D = (X, Y)$, 其中输入空间的特征集合为 $A = \{\alpha_1, \alpha_2, \dots, \alpha_k\}$, 输出空间的标签集合为 $B = \{\beta_1, \beta_2, \dots, \beta_l\}$, representation learning 层中参数为 $(\Theta_G, B_G) = \{(\Theta_1, B_1), (\Theta_2, B_2), \dots, (\Theta_n, B_n)\}$, forests learning 层中参数为 $(structure, W_f, B_f)$, 其中 $(W_f, B_f) =$

$\{(W_1, B_1), (W_2, B_2), \dots, (W_{n_{tree}}, B_{n_{tree}})\}$, 分别表示不同树结构参数, 任意 $(W_i, B_i) \in (W_f, B_f)$, 有 $(W_i, B_i) = \{W_{node}, B_{node}, W_{leaf}, B_{leaf}\}$, 其中 (W_{node}, B_{node}) 表示树结构 i 的非叶节点参数, (W_{leaf}, B_{leaf}) 表示树结构 i 的叶节点参数。 $structure = \{depth, n_{tree}\}$, 其中 $depth$ 表示森林模型中每棵树深度, n_{tree} 表示森林模型中树的个数, 此模型最终预测结果为

$$\hat{y} = \operatorname{argmax}(\psi(\beta|E, structure, W_f, B_f)) \quad (1)$$

其中:

$$E = \sum_{i=1}^n g_i(X_{A_i}, \theta_{g_i}, B_{g_i}) \quad (2)$$

到稿日期: 2017-12-27 返修日期: 2017-00-00 本文受国家重点研发计划政府间国际科技创新合作重点专项(2016YFE0108000)资助。

石雪怀 (1995-), 男, 硕士研究生, 主要研究方向: 数据挖掘; 戚湧 (1970-), 男, 博士, 教授, 博士生导师, 通讯作者, CCF 高级会员 (E2000228665), 主要研究方向: 数据挖掘, E-mail: 790815561@qq.com; 李千目 (1979-), 男, 博士, 教授, 博士生导师, 主要研究方向: 数据挖掘。

为 representation learning 层的输出, g_i 表示一个非线性激励函数集合, Σ 表示级联操作, ψ 用于描述 forests learning 层的操作。

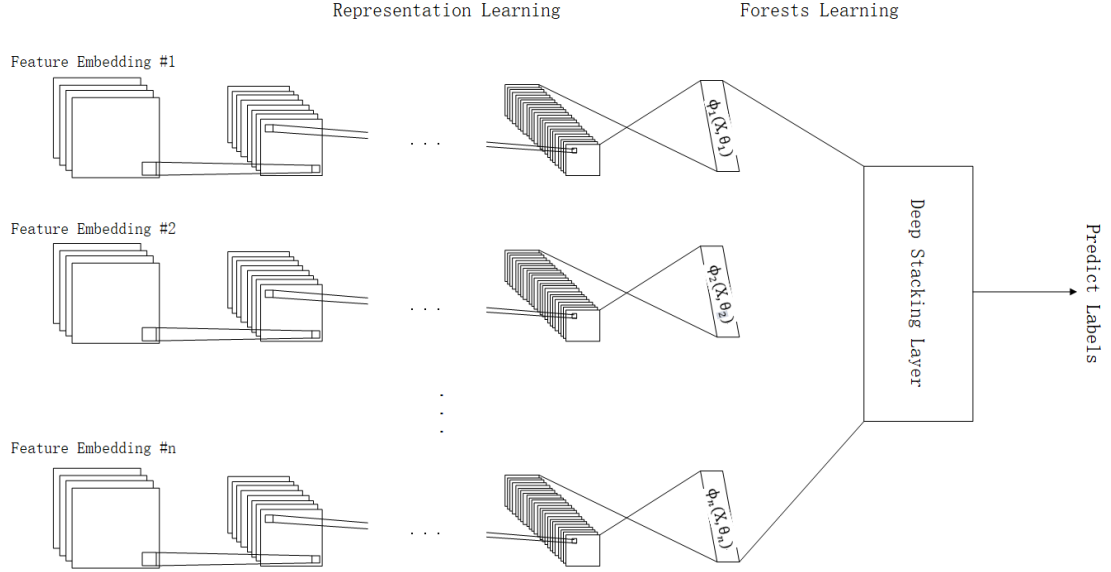


图 2. 深度集成模型总体框架图

4.1.1 Representation Learning 层

Representation Learning 层旨在以某种规则组合建立从原始特征空间到多个特征子空间集合的映射, 提取原始特征空间中不同特征之间的相关信息, 如从原始特征空间中筛选将包含稀疏独热张量、类别特征或密集连续特征等不同类型的特征子空间映射到另一个特征子空间完成表示学习。在事故预警系统中, 特征空间 $A = \{\text{天气, 温度, 风级, 风向, 湿度, 建筑物数据特征}\}$, Representation Learning 层对 A 组合: $\{A_1 = (\text{天气, 温度, 风级, 风向, 湿度}), A_2 = (\text{建筑物数据特征}), A_3 = (\text{天气, 温度, 风级, 风向, 湿度, 建筑物数据特征})\}$ 且 $A = A_1 \cup A_2 \cup A_3$, 有

$$e_i = g_i(X_{A_i}, \theta_{g_i}, B_{g_i}) \quad (3)$$

为 A_i 特征子空间在 Representation Learning 层的输出。最终输出

$$E = [e_1, e_2, \dots, e_n] \quad (4)$$

Representation Learning 层将所有的 feature embedding 结果连接, 生成张量 E 传入 Forests Learning 层。

4.1.2 Forests Learning 层

Forests Learning 层建立表示学习结果到输出空间之间的映射, 本文中 Forest Learning 层使用随机森林如公式 1 所示 $RF = \psi(\beta|E, structure, W_f, B_f)$, 不同于随机森林中树模型使用局部贪婪优化算法确定每棵树的结构,

本模型中森林结构需要固定, 本文使用[随机森林\[13\]](#)初始化 *structure*, 之后的工作会寻求最优 *structure*。

本文使用[分裂函数模糊化方法\[17\]](#)确定森林模型中每个树结构的节点参数。任意树 $t \in RF$, 有 $t = \{node, leaf\}$, 其中 *node* 为树结构中所有非叶节点集合, *leaf* 为树结构中所有叶节点集合。任意 $o \in node$, 有

$$\begin{aligned} s_{o_l}(x|w_o, b_o) &= \frac{1}{1 + e^{-(w_o x + b_o)}} \\ s_{o_r}(x|w_o, b_o) &= \frac{1}{1 + e^{(w_o x + b_o)}} \end{aligned} \quad (5)$$

为非叶节点 o 的分裂函数, 可知 $s_{o_l} + s_{o_r} = 1$ 。任意 $\beta \in leaf$, 有

$$\begin{aligned} d_{\beta_j}(s|w_{\beta_j}, b_{\beta_j}) &= \frac{e^{(w_{\beta_j} s + b_{\beta_j})}}{1 + \sum_{i=0}^{l-1} e^{(w_{\beta_i} s + b_{\beta_i})}} \quad \text{if } j=0, \dots, l-2 \\ d_{\beta_j}(s|w_{\beta_j}, b_{\beta_j}) &= \frac{1}{1 + \sum_{i=0}^{l-1} e^{(w_{\beta_i} s + b_{\beta_i})}} \quad \text{else} \end{aligned} \quad (7)$$

为叶节点对应标签集合 $B = \{\beta_1, \beta_2, \dots, \beta_l\}$ 的决策函数, 可知 $\sum_{i=0}^{l-1} d_{\beta_i} = 1$ 。任意 $e \in E$, 此树结构 t 输出

$$output_t = \psi_t(e|w_t, b_t) \quad (8)$$

有

$$\psi_t = \sum_{\beta \in leaf} (d_{\beta_i} \times path(e|\beta)) \quad i=0, \dots, l-1 \quad (9)$$

path 为 e 到达该叶节点 β 对应的路径, 任意 $e \in E$,

有

$$path(e|\beta) =$$

$$\prod_{l \in node} s_{0l}(x|w_0, b_0)^{1(3 \leftarrow 0)} \times s_{0r}(x|w_0, b_0)^{1(0 \rightarrow 3)} \quad (10)$$

其中, 假设 l, m, r 为树结构的结点, 有 $l \leftarrow m$ 表示 l 为 m 的左孩子结点, $m \rightarrow r$ 表示 r 为 m 的右孩子结点。 $1(c)$ 表示示性函数, 若 c 为真则 $1(c)=1$ 否则 $1(c)=0$ 。 $\psi_t \in R^{m \times l}$, 其中 m 为数据块长度, l 为输出的维度。最终, Forests Learning 层的输出为

$$output = \arg\max_{\beta} \left(\frac{\sum_{t \in RF} \psi_t}{|RF|} \right) \quad (11)$$

$|\cdot|$ 函数用以描述 \cdot 集合包含的元素个数, $output$ 为模型最终输出结果。

4.2 训练方法

对于数据集 $D = (X, Y)$, 本文的目标为最小化如下函数

$$loss = -\frac{1}{|D|} \sum_{(x,y) \in (X,Y)} (\log(output(x)) \times y) \quad (12)$$

即

$$target = \min_{W_f, B_f, \Theta_G, B_G} (loss) \quad (13)$$

$output$ 函数如公式 11 所示, 本文采用**随机梯度下降法**[18]同时优化 W_f, B_f, Θ_G, B_G 。由上述可知参数 $(W_f, B_f) = \{W_{node}, B_{node}, W_{leaf}, B_{leaf}\}$, 任意 $3 \in leaf$, 有

$$W_3^{(t+1)} = W_3^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial d} \times \frac{\partial d}{\partial W_3} \quad (14)$$

$$b_3^{(t+1)} = b_3^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial d} \times \frac{\partial d}{\partial b_3} \quad (15)$$

任意 $0 \in node$, 有

$$W_0^{(t+1)} = W_0^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial path} \times \frac{\partial path}{\partial W_0} \quad (16)$$

$$b_0^{(t+1)} = b_0^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial path} \times \frac{\partial path}{\partial b_0} \quad (17)$$

对于 Representation Learning 层, 任意 $(\Theta_{g_i}, B_{g_i}) \in (\Theta_G, B_G)$, 有

$$\Theta_{g_i}^{(t+1)} = \Theta_{g_i}^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial e} \times \frac{\partial e}{\partial g_i} \times \frac{\partial g_i}{\partial \Theta_{g_i}} \quad (18)$$

$$B_{g_i}^{(t+1)} = B_{g_i}^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial e} \times \frac{\partial e}{\partial g_i} \times \frac{\partial g_i}{\partial B_{g_i}} \quad (19)$$

算法 1 深度集成模型

输入:

数据集 $D=(X,Y)$

输入空间的特征集合为 $A = \{\alpha_1, \alpha_2, \dots, \alpha_k\}$,

输出空间的标签集合为 $B = \{\beta_1, \beta_2, \dots, \beta_l\}$

训练:

建立原始特征空间到多个特征子空间集合的映射 $\{A_1, A_2, \dots, A_n\}$, 且 $A_1 \cup A_2 \cup \dots \cup A_n = A$ 。

根据随机森林算法初始化 $(structure, W_f, B_f)$

初始化 Representation Learning 层参数 (Θ_G, B_G)

Repeat:

根据公式 14, 15 优化 Forest Learning 层叶节点参数 (W_{leaf}, B_{leaf})

根据公式 16, 17 优化 Forest Learning 层非叶节点参数 (W_{node}, B_{node})

根据公式 18, 19 优化 Representation Learning 层参数 (Θ_G, B_G)

Until convergence

测试:

根据公式 11 输出预测结果

5. 实验

5.1 事故预警

由于数据集的不平衡性, 本系统采用组合/集成方式对数据集进行批次训练, 即将非正常类别样本 (即结果标签为 1、2、3 的样本) 随机分为 100 份 (当然也可以分更多), 每份 100 条数据, 每批次中包含正常类别样本 (结果标签为 0 的样本 100 条) 和随机抽取的非正常类别样本 (结果标签为 1、2、3 的样本共 300 条), 如此反复进行集成训练。将清洗完成的数据使用深度集成模型方法训练, 输入空间选取的特征包括{天气, 温度, 风级, 风向, 湿度, 建筑物数据特征}, 建筑物数据特征如表 1 所示。

根据模型生成报告, 如图 3 所示, 模型预测精度为 0.9, 测试集上平均误差为 0.1, 测试误差的标准偏差为 0.044721, 火灾预警模型生成的火灾预警系统界面截图如图 4 所示。

```
Model Report
Accuracy: 0.9
test-auc-mean and test-auc-std and train-auc-mean and train-auc-std:
test-merror-mean 0.1
test-error-std 0.044721
Name: 82, dtype: float64 Accuracy: 0.9
```

图 3. 模型信息报告



图 4. 火灾预警系统界面截图

5.2 其他实验

5.2.1 Caltech 4

为了证明本方法对小规模数据集的友好性,本文选择使用 Caltech 4 数据集作为实验对象。Caltech 4[19]是一个自然图像数据集,包含 4 种类别的图像 (air, face, leo, motor), 本实验的任务为基于 Caltech 4 的图像分类, Caltech 4 数据集中每个图像大小为 300×200 像素, 本文使用的 Representation Learning 中 Feature Embedding 个数为 5, 在相同计算环境下比较 GoogLeNet 和基于 GoogLeNet 深度集成模型的性能, 由表 2 的实验结果说明可知基于 GoogLeNet 深度集成模型在此数据集上总体效果略好于 GoogLeNet, 证明基于 GoogLeNet 深度集成模型在非规模大数据集上具有更强的学习能力。

5.2.2 ImageNet

ImageNet[20]是一个大规模图像识别任务, 在相同计算环境下比较 GoogLeNet 和基于 GoogLeNet 深度集成模型的性能, 并多次重复该实验。由表 2 的实验结果说明可知基于 GoogLeNet 深度集成模型在此数据集上平均误差为 7.27%, GoogLeNet 在此数据集上平均误差为 7.26%, 表现不差于 GoogLeNet, 且最优误差率略好于 GoogLeNet。

表 2. 模型预测结果 Top3-Error (%)

	GoogLeNet			基于 GoogLeNet 的深度集成模型		
Caltech 101	3.2	3.4	3.8	2.8	2.9	2.9
ImageNet	6.67	7.51	7.62	6.65	7.56	7.6

6. 结论

本文结合深度学习和集成模型两者优点, 提供一种基于深度集成模型的事故预警方法, 此方法根据不同类型建筑的火灾特点, 使用多个神经网络进行特征学习, 使用一种集成神经森林模型结合特征学习结果进行预测, 并使用一种全局优化方法完成参数优化。实验表明本方法对火灾事故预警提供了一种较为可行的解决方案, 且结合 googLeNet 在其他任务仍有优秀的表现结果。

本文中 Forest Learning 层结构根据随机森林训练结果进行初始化并固定 Forest Learning 层结构, 之后的工作会寻求一种方法优化 Forest Learning 层结构以在不损失模型预测精度的情况下降低模型计算成本。未来可以结合时间序列这一关键因素提取各类信息在时间维度上的特征, 将分析结果作为新的特征加入火灾预警模型, 进一步提

升模型预测精度。因此, 将此方法应用于消防预警系统, 更好的为城市消防提供帮助, 使城市消防趋向智能化, 这也是智慧城市建设中重要的一部分。

参考文献

- [1] 郑双忠, 邓云峰, 蒋清华. 基于火灾统计灾情数据的城市火灾风险分析[J]. 中国安全生产科学技术, 2005, 1(3):15-18.
- [2] 张学林, 孙志友, 汪金辉, 等. 基于马尔可夫链的城市火灾预测 [J]. 火灾科学, 2006, 15(3):168-171.
- [3] 刘德志. 城市火灾报警智能监控终端的研究与应用[D]. 广东工业大学, 2013.
- [4] Sharma D, Singh K, Aggarwal S. Implementation of Artificial Neural Fuzzy Inference System in a Real Time Fire Detection Mechanism[J]. International Journal of Computer Applications, 2016, 146(10).
- [5] Alamgir N, Boles W, Chandran V. A Model Integrating Conflagration prediction and Detection for Rural-Urban Interface[C]// International Conference on Digital Image Computing: Techniques and Applications. IEEE, 2016:1-8.
- [6] Gao D, Lin H, Jiang A, et al. A forest conflagration prediction system based on rechargeable wireless sensor networks[C]// IEEE International Conference on Network Infrastructure and Digital Content. IEEE, 2015:405-408.
- [7] Wang X, Wotton B M, Cantin A S, et al. cffdrs: an R package for the Canadian Forest Fire Danger Rating System[J]. Ecological Processes, 2017, 6(1):5.
- [8] Oliveira A, Nero M. Application of Fuzzy Logic in Prediction of Fire in João Pessoa City - Brazil[M]// Geo-Informatics in Resource Management and Sustainable Ecosystem. Springer Berlin Heidelberg, 2013:323-334.
- [9] Schmidhuber J. Deep Learning in neural networks: An overview.[J]. Neural Netw, 2015, 61:85-117.
- [10] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.

- [11] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]// INTERSPEECH 2010, Conference of the International Speech Communication Association, Makuhari, Chiba, Japan, September. DBLP, 2010:1045-1048.
- [12] Jerome H. Friedman. Greedy Function Approximation: A Gradient Boosting Machine[J]. The Annals of Statistics, 2001, 29(5):1189-1232.
- [13] Ho T K. Random Decision Forests[J]. Icdar, 1995, 1:278-282 vol.1.
- [14] Richmond D L, Kainmueller D, Yang M, et al. Mapping stacked decision forests to deep and sparse convolutional neural networks for semantic segmentation[C]//Proc. British Machine Vision Conference. 2015.
- [15] Kotschieder P, Fiterau M, Criminisi A, et al. Deep Neural Decision Forests[C]// IEEE International Conference on Computer Vision. IEEE, 2016:1467-1475.
- [16] Zhou Z H, Feng J. Deep Forest: Towards An Alternative to Deep Neural Networks[J]. 2017.
- [17] Suarez A, Lutsko J F. Globally optimal fuzzy decision trees for classification and regression[J]. Pattern Analysis & Machine Intelligence IEEE Transactions on, 1999, 21(12):1297-1311.
- [18] Kiwiel K C. Convergence and efficiency of subgradient methods for quasiconvex minimization[J]. Mathematical Programming, 2001, 90(1):1-25.
- [19] Li F F, Fergus R, Perona P. Learning Generative Visual Models from Few Training Examples: An Incremental Bayesian Approach Tested on 101 Object Categories[C]// Computer Vision and Pattern Recognition
- [20] Russakovsky O, Deng J, Su H, et al. Imagenet large scale visual recognition challenge[J]. International Journal of Computer Vision, 2015, 115(3): 211-252.
- [21] Taylor S W, Alexander M E. Field guide to the Canadian Forest Fire Behavior Prediction (FBP) System. (BINDER)[M]. 2016.
- [22] 伍爱友, 施式亮, 王从陆. 基于神经网络和遗传算法的城市火灾风险评价模型[J]. 中国安全科学学报, 2006, 16(11):108-113.
- [23] 方正, 陈娟娟, 谢涛, 等. 基于聚类分析和AHP 的商场类建筑火灾风险评估[J]. 东北大学学报(自然科学版), 2015, 36(3):442-447.
- [24] Yang L, Dawson C W, Brown M R, et al. Neural network and GA approaches for dwelling fire occurrence prediction[J]. Knowledge-Based Systems, 2006, 19(4):213-219.