

# 基于深度集成模型的事故预警方法

石雪怀<sup>1</sup>, 戚湧<sup>1</sup>, 李千目<sup>1</sup>, 张伟斌<sup>2</sup>

(1. 南京理工大学计算机科学与工程学院, 江苏南京 210094; 2. 南京理工大学电子工程与光电技术学院, 江苏南京 210094)

**摘要:** 城市火灾作为社会公共安全的重要威胁源, 是一种随机事件, 如何根据当前状态数据极早地发出预警信息是一个亟需解决的问题。本文提出一种新的火灾事故预警方法, 根据多种传感器数据和建筑的致灾因子和损失控制因子数据, 基于深度神经网络进行特征学习, 结合知识库规则学习结果代入集成神经森林模型进行火灾事故预警, 并使用一种全局优化方法完成深度神经网络和集成神经森林模型的参数优化, 提升预测精度。实验表明, 本方法为火灾事故预警提供了一种良好的解决方案, 本方法与单一集成模型和深度学习模型相比有更好的预警效果。

**关键词:** 深度学习; 事故预警

**中图分类号:** TP391 **文献标志码:** A

## An Accident Warning Approach Based On Deep Stacking Model

SHI Xuehuai<sup>1</sup>, QI Yong<sup>1</sup>, LI Qianmu<sup>1</sup>, ZHANG Weibin<sup>2</sup>

(1. School of Computer Science and Engineering, Nanjing University of Science and Technology, 210094, China; 2. School of Electronic & Optical Engineering, Nanjing University of Science and Technology, 210094, China)

**Abstract:** As an important threat to public security, predicting and analyzing the interior rule of urban fire accident from its appearance needed to be solved. This paper proposes a new fire accident warning system based on multi-sensors and various disaster-inducing factors. Learning features from multi-sensors data and intrinsic data of different buildings via multi-NNs. Using a deep neural decision forest predicts the objective based on the learning features from multi-NNs and the knowledge base rule. The task of optimizing the parameters in multi-NNs and deep neural decision forest in parallel is achieved via a global optimization method. Experiments from fire accident warning system prove the efficacy of the proposed approach with the state of the art.

**Key words:** deep learning; accident warning

## 0. 引言

通过对火灾事故的历史数据和当前状态数据进行分析, 火灾事故预警系统必须根据当前状态数据极早地发出预警信息, 并根据预警信息定制个性化决策, 从而减少损失和极力避免火灾发生。火灾事故预警问题可以认为是一种异常检测问题, 其系统的建立难点在于: 1. 现阶段由于探测器的缺失, 建筑物相关致灾因子数据和损失控制因子数据的稀少或缺失, 很难依据建筑物自身特点和建筑物内部动态数据建立详细可操作的火灾事故预警系统; 2. 火灾事故预警系统能否根据相关因子数据提取知识, 最终提供准确的即时预警信息。现有火灾预警系统主要分为两类: 基于知识库规则的预警系统<sup>[10, 11, 13]</sup>, 基于机器学习方法的预警系统<sup>[7, 8, 9, 12]</sup>。基于知识库规则的预警系统从温度传感器、烟雾传感器、自动防火器等装置获取相关数据, 通过模糊推理等规则提取相关知识并最终作出预警决策。在传感器类型较少的情况下, 此类方法可以依据先验知识充分挖掘不同类型数据之间的相关性, 并作出有效的预警决策, 但在传感器类型较多的情况下, 此类方法无法充分考虑各种类型数据之间的关联, 很难依据大量不同类型的传感器和建筑物自身数据建立详细可操作的火灾事故预警系统。基于机器学习方法的预警

系统能够结合大量不同类型的传感器和建筑物自身数据, 提取信息作出有效的事故预警决策, 但由于火灾事故属于偶然事件, 其相关数据的获取难度较大, 基于机器学习方法的预警系统在传感器类型较少(即特征空间较小)和训练数据较少的情况下易出现过拟合或欠拟合的情况, 很难学习不同类型数据之间关系并建立有效的预警系统。

因此, 结合知识库规则和深度学习算法的优势建立火灾事故预警系统成为一种可行的解决方案。但如何将基于知识库规则提取特征集合与基于深度学习模型提取的特征集合结合成为一个难题。本文结合深度神经网络和知识库规则的优势, 研究基于深度集成模型的事​​故预警方法, 此方法根据建筑的致灾因子和损失控制因子提取特征, 结合知识库提取的特征集合, 代入一种集成神经森林模型学习, 使用一种全局优化方法完成参数优化, 为建筑物提供火灾事故预警。

## 1. 研究现状

### 1.1 事故预警

国内外学者基于不同的目标开展了不同的火灾预警系统的研究。如在文献[6-8]中, 郑双忠等从宏观角度, 根据历史火灾数据, 对本年度及下年度火灾进行预测; Sharma D 等[9]基于提供人工神经网络

接口的硬件模型建立火灾检测和控制机制，此硬件模型包含温度感应器、烟雾感应器、火花感应器及微控制器单元，但没有考虑人为因素及建筑物老化等其他因素对火灾致灾的影响；Alamgir N 等[10]依据天气参数及通过视频监控设备探测烟雾级别作为火灾事故预警信号来建立火灾事故预警模型，此模型评估隐患火灾，提供火灾危险指数，此模型适用于植物群落地区，通过探测烟雾级别作为火灾事故预警信号，适用场景较为局限，此外 Gao D[11]和 Wang X 等[12]致力于森林火灾预测领域，也做出了显著贡献；Oliveira A 和 Nero M[13]基于城市 GIS 数据获取地形、人口密度、水道、道路、不合标准的住房和降雨信息使用多准则决策方法建立城市火灾预警系统。由于探测器的缺失，现阶段没有依据建筑物自身特点和建筑物内部动态数据进行相关性分析建立模型的思路，现有火灾事故预警几乎都是宏观的事故率预测，缺少详细可操作的微观事故风险预警。

### 1.2 深度集成模型

随着计算资源的不断提升，近年来深度神经网络<sup>[1,2,3]</sup>作为一种新的机器学习方法开始受到研究人员的高度关注。针对大数据，深度学习能够通过底层的特征组合，抽象高层特征来实现数据的分布式表示，从而可以更好地刻画出数据的本质特征。尽管深度神经网络功能强大，其缺点也很明显：一是模型训练需要大量数据，对小规模数据不友好；二是模型过于复杂，需要大量计算资源；三是超参数过多，模型调参困难。而集成学习以其优异的运行效率和模型性能已成功应用于多个领域，如梯度提升树<sup>[4]</sup>、随机森林<sup>[5]</sup>等，但由于模型难以表述复杂的非线性关系，也难以获取深度知识对原始数据中优秀的抽象特征进行提取。

在事故预警中，人工的特征提取需要消耗大量资源，深度学习作为一种有效的特征提取工具在学术界和工业界具有广泛的应用，在大数据和计算资源的支持下 LeNet、FPGAs 取得了卓越的成就，但在事故预警系统中，有标签数据相对不多，难以满足深度学习模型的学习需求。

针对上述问题，国内外研究人员尝试将深度学习与集成模型结合，如 DL Richmond 等<sup>[14]</sup>提出一种基于决策森林和卷积神经网络的映射模型，提供一种激励反馈机制，用随机森林为 Cnns 提供更好初始化，更优秀的 Cnns 反作用于随机森林，提升随机森林的表现。P Kontschieder 等<sup>[15]</sup>于 2016 年提出深度神经决策森林，此模型将深度学习网络与决策树结合，此方法不同于传统神经网络在于其使用决策森林作出最终预测，不同于传统森林模型的贪婪局部最优的方法寻找分裂节点生成决策树，此模型提出一种规则化的联合全局最优方法优化决策树的节点参数，实验结果表明在 ImageNet 数据集上，此模型结合 GoogleNet 模型表现优于最新的一些深度学习模型。周志华等<sup>[16]</sup>于 2017 提出 deep forest，该方法是一种决策树集成模型，通过一种级联结构生成

深度树模型使模型具有更好的表示学习能力，根据卷积神经网络获得的灵感，针对高维数据提出多粒度扫描法获取数据的上下文及结构信息，实验结果表明此方法具有较少的超参数且对于小规模数据更加友好，针对同量级数据此法模型复杂度相对深度神经网络更低。基于之前的研究成果，集成学习与深度学习的融合成为了一个新的研究热点，适合于火灾事故预警。

表 1. 住宅建筑数据特征

建筑类型	住宅建筑		
致灾因子	燃气方式	人口密度	电气设备安全级别
	内部装修安全级别	建筑物结构	建筑物高度
	屋龄		
损失控制因子	耐火等级	防火隔离级别	安全疏散级别
	安全监控装备级别	室内消火栓装备级别	手提灭火器装备级别

### 2. 问题描述

本文利用 2011 年至 2017 年深圳市发生火灾的建筑物、当时天气相关数据以及该火灾致灾原因相关数据，建立火灾事故预警系统，数据特征包括{天气, 温度, 风级, 风向, 湿度, 烟雾探测器数据, 建筑物数据特征}。住宅建筑物数据特征如表 1 所示，公共建筑、厂房建筑和仓库建筑特征与住宅建筑有细微差别，主要表现在损失控制因子。根据建筑物不同使用性质，具有不同特征，这些特征用数值描述。标签数据特征为火灾预警等级，包括：0. 正常无隐患 1. 有隐患。

因为影响火灾发生的因素非常复杂，除了建筑物自身特性，还有商业地区易燃物聚集以及住宅区电路老化、居民防火意识薄弱等等。现阶段无法针对所有影响火灾发生因素进行分析，且选取数据信息因调研目的不同而有所区别。基于上述原因，本文只选取住宅建筑作为实验数据，对住宅建筑建立火灾事故预警系统，其他三类建筑模型建立方法与此类似。

### 3. 深度集成模型

#### 4.1 总体框架

本文致力于构建一个深度集成模型来建立火灾事故预警系统，算法伪代码如算法 1 所示，总体框架图如图 2 所示。由图 2 可知，此模型包含两个部分：Representation Learning 层和 Forest Learning 层。Representation Learning 层分为两部分，基于知识库规则的特征学习模块与基于深度学习模型的特征学习模块；Forest Learning 层对 Representation Learning 层的学习结果使用一种集成神经森林模型进行学习，最终为建筑物提供火灾事故预警。

假设一个分类问题中，数据集为  $D = (X, Y)$ ，其中输入空间的特征集合为  $A = \{\alpha_1, \alpha_2, \dots, \alpha_k\}$ ，输出空间的标签集合为  $B = \{\beta_0, \beta_1, \dots, \beta_{l-1}\}$ （在本文中  $B = \{\beta_0, \beta_1\}$ ），representation learning 层中参数为  $(\Theta_G, B_G) = \{(\Theta_1, B_1), (\Theta_2, B_2), \dots, (\Theta_n, B_n)\}$ ，forests

learning 层中参数为 $(structure, W_f, B_f)$ , 其中 $(W_f, B_f) = \{(W_1, B_1), (W_2, B_2), \dots, (W_{n_{tree}}, B_{n_{tree}})\}$ , 分别表示不同树结构参数, 任意 $(W_i, B_i) \in (W_f, B_f)$ , 有 $(W_i, B_i) = \{W_{node}, B_{node}, W_{leaf}, B_{leaf}\}$ , 其中 $(W_{node}, B_{node})$ 表示树结构 $i$ 的非叶节点参数,  $(W_{leaf}, B_{leaf})$ 表示树结构 $i$ 的叶节点参数。 $structure = \{depth, n_{tree}\}$ , 其中 $depth$ 表示森林模型中每棵树深度,  $n_{tree}$ 表示森林模型中树的个数, 此模型最终预测结果为:

$$\hat{y} = \operatorname{argmax}(\psi(\beta|E, structure, W_f, B_f)) \quad (1)$$

其中:

$$E = \sum_{i=1}^n g_i(X_{A_i}, \theta_{g_i}, B_{g_i}) \quad (2)$$

为representation learning 层的输出,  $g_i$ 表示一个非线性激励函数集合,  $\Sigma$ 表示级联操作,  $\psi$ 用于描述forests learning 层的操作。

算法 1 深度集成模型

输入:

---

数据集  $D=(X, Y)$   
 输入空间的特征集合为  $A = \{a_1, a_2, \dots, a_k\}$ , 输出空间的标签集合为  $B = \{\beta_1, \beta_2, \dots, \beta_l\}$   
 训练:  
   建立原始特征空间到多个特征子空间集合的映射  $\{A_1, A_2, \dots, A_n\}$ , 且  $A_1 \cup A_2 \cup \dots \cup A_n = A$ 。  
   根据随机森林算法初始化 $(structure, W_f, B_f)$   
   初始化 Representation Learning 层参数 $(\Theta_G, B_G)$   
   Repeat:  
     根据公式 14, 15 优化 Forest Learning 层叶节点参数 $(W_{leaf}, B_{leaf})$   
     根据公式 16, 17 优化 Forest Learning 层非叶节点参数 $(W_{node}, B_{node})$   
     根据公式 18, 19 优化 Representation Learning 层参数 $(\Theta_G, B_G)$   
   Until convergence  
 测试:  
   根据公式 11 输出预测结果

---

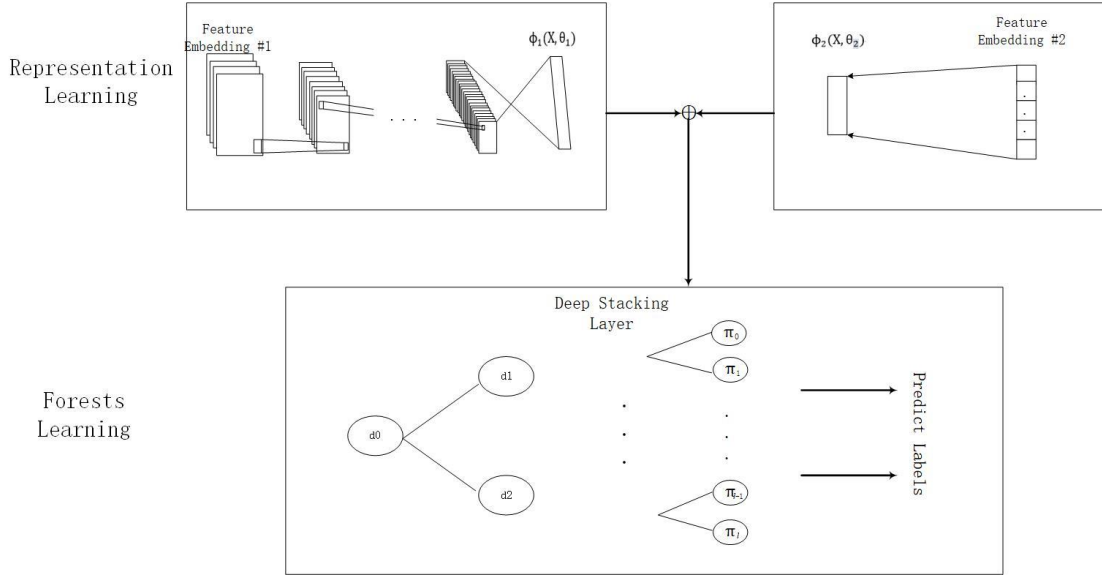


图 1. 深度集成模型总体框架图

#### 4.1.1 Representation Learning 层

Representation Learning 层分为两部分, 基于知识库规则的特征学习模块与基于深度学习模型的特征学习模块, 旨在以某种规则组合建立从原始特征空间到多个特征子空间集合的映射, 提取原始特征空间中不同特征之间的相关信息, 如从原始特征空间中筛选将包含稀疏独热张量、类别特征或密集连续特征等不同类型的特征子空间映射到另一个特征子空间完成表示学习。在事故预警系统中, 特征空间  $A = \{\text{天气, 温度, 风级, 风向, 湿度, 烟雾探测器数据, 建筑物数据特征}\}$ , 令  $A = \{\text{feature embedding \#1, feature embedding \#2}\}$ , 其中  $\text{feature embedding \#1} = \{\text{天气, 温度, 风级, 风向, 湿度, 烟雾探测器数据, 建筑物数据特征}\}$ ,  $\text{feature embedding \#2} = \{\text{天气, 温度, 风级, 风向, 湿度, 烟雾探测器数据}\}$ 。

风级, 风向, 湿度, 烟雾探测器数据}, 有:

$$\begin{aligned} e_1 &= g_1(X_{A_1}, \theta_{g_1}, B_{g_1}) \\ e_2 &= g_2(X_{A_2}, \theta_{g_2}, B_{g_2}) \end{aligned} \quad (3)$$

其中 $A_1$ 为feature embedding #1对应的特征集合,  $X_{A_1}$ 为 $A_1$ 对应的数据,  $\theta_{g_1}, B_{g_1}$ 为基于深度学习模型的特征学习模块 $g_1$ 的参数,  $e_1$ 为基于深度学习模型的特征学习模块输出;  $A_2$ 为feature embedding #2对应的特征集合,  $X_{A_2}$ 为 $A_2$ 对应的数据,  $\theta_{g_2}$ 为基于知识库规则的特征学习模块 $g_2$ 的参数(本文使用基于温度、烟雾传感器的模糊逻辑系统),  $e_2$ 为基于知识库规则的特征学习模块输出。最终输出

$$E = [e_1, e_2] \quad (4)$$

Representation Learning 层将两个模块输出结果连接, 生成张量  $E$  传入 Forests Learning 层。

#### 4.1.2 Forest Learning 层

Forests Learning 层建立表示学习结果到输出空间之间的映射, 本文中 Forest Learning 层使用

随机森林如公式 1 所示  $RF = \psi(\beta|E, structure, W_f, B_f)$ , 不同于随机森林中树模型使用局部贪婪优化算法确定每棵树的结构, 本模型中森林结构需要固定, 本文使用随机森林[13]初始化  $structure$ , 之后的工作会寻求最优  $structure$ 。

本文使用分裂函数模糊化方法<sup>[17]</sup>确定森林模型中每个树结构的节点参数。任意树  $t \in RF$ , 有  $t = \{node, leaf\}$ , 其中  $node$  为树结构中所有非叶节点集合,  $leaf$  为树结构中所有叶节点集合。任意  $o \in node$ , 有:

$$\begin{aligned} s_{o_l}(x|w_o, b_o) &= \frac{1}{1+e^{-(w_o x + b_o)}} \\ s_{o_r}(x|w_o, b_o) &= \frac{1}{1+e^{(w_o x + b_o)}} \end{aligned} \quad (5)$$

$s_{o_r}(x|w_o, b_o)$  为非叶节点  $o$  的分裂函数, 可知

$s_{o_l} + s_{o_r} = 1$ 。任意  $j \in leaf$ , 有:

$$\begin{aligned} d_{3_j}(s|w_3, b_3) &= \frac{e^{(w_{3_j}s + b_{3_j})}}{1 + \sum_{i=0}^{l-1} e^{(w_{3_i}s + b_{3_i})}} \quad \text{if } j=0, \dots, l-2 \\ d_{3_j}(s|w_3, b_3) &= \frac{1}{1 + \sum_{i=0}^{l-1} e^{(w_{3_i}s + b_{3_i})}} \quad \text{else} \end{aligned} \quad (7)$$

$d_{3_j}(s|w_3, b_3)$  为叶节点对应标签集合  $B = \{\beta_1, \beta_2, \dots, \beta_l\}$  的决策函数, 可知  $\sum_{i=0}^{l-1} d_{3_i} = 1$ 。任意  $e \in E$ , 此树结构  $t$  输出

$$output_t = \psi_t(e|w_t, b_t) \quad (8)$$

有:

$$\psi_t = \sum_{j \in leaf} (d_{3_j} \times path(e|3_j)) \quad i=0, \dots, l-1 \quad (9)$$

$path$  为  $e$  到达该叶节点  $3_j$  对应的路径, 任意  $e \in E$ , 有:

$$\begin{aligned} path(e|3_j) &= \prod_{o \in node} s_{o_l}(x|w_o, b_o)^{1(3 \rightarrow o)} \times \\ &\quad s_{o_r}(x|w_o, b_o)^{1(o \rightarrow 3)} \end{aligned} \quad (10)$$

其中, 假设  $l, m, r$  为树结构的结点, 有  $l \leftarrow m$  表示  $l$  为  $m$  的左孩子结点,  $m \rightarrow r$  表示  $r$  为  $m$  的右孩子结点。 $1(c)$  表示示性函数, 若  $c$  为真则  $1(c)=1$  否则  $1(c)=0$ 。 $\psi_t \in R^{m \times l}$ , 其中  $m$  为数据块长度,  $l$  为输出的维度。最终, Forests Learning 层的输出为:

$$output = \argmax_{\beta} \left( \frac{\sum_{t \in RF} \psi_t}{|RF|} \right) \quad (11)$$

$|\cdot|$  函数用以描述  $\cdot$  集合包含的元素个数,  $output$  为模型最终输出结果。

## 4.2 训练方法

对于数据集  $D = (X, Y)$ , 本文的目标为最小化如下函数:

$$loss = -\frac{1}{|D|} \sum_{(x,y) \in (X,Y)} (\log(output(x)) \times y) \quad (12)$$

即:

$$target = \min_{W_f, B_f, \Theta_G, B_G} (loss) \quad (13)$$

$output$  函数如公式 11 所示, 本文采用随机梯度下降法[18]同时优化  $W_f, B_f, \Theta_G, B_G$ 。由上述可知参数  $(W_f, B_f) = \{W_{node}, B_{node}, W_{leaf}, B_{leaf}\}$ , 任意  $j \in leaf$ , 有:

$$W_3^{(t+1)} = W_3^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial d} \times \frac{\partial d}{\partial W_3} \quad (14)$$

$$b_3^{(t+1)} = b_3^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial d} \times \frac{\partial d}{\partial b_3} \quad (15)$$

任意  $o \in node$ , 有:

$$W_o^{(t+1)} = W_o^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial path} \times \frac{\partial path}{\partial W_o} \quad (16)$$

$$b_o^{(t+1)} = b_o^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial path} \times \frac{\partial path}{\partial b_o} \quad (17)$$

对于 Representation Learning 层, 任意  $(\Theta_{g_i}, B_{g_i}) \in (\Theta_G, B_G)$ , 有:

$$\Theta_{g_i}^{(t+1)} = \Theta_{g_i}^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial e} \times \frac{\partial e}{\partial \Theta_{g_i}} \times \frac{\partial \Theta_{g_i}}{\partial \Theta_{g_i}} \quad (18)$$

$$B_{g_i}^{(t+1)} = B_{g_i}^{(t)} - \eta \times \frac{\partial loss}{\partial \psi} \times \frac{\partial \psi}{\partial e} \times \frac{\partial e}{\partial B_{g_i}} \times \frac{\partial B_{g_i}}{\partial B_{g_i}} \quad (19)$$

## 4. 实验

由于数据集的不平衡性, 本文采用批量梯度下降法对数据集进行批次训练, 即将训练集 (即结果标签为 0、1 的样本) 随机分为 100 份, 每份 300 条数据, 每批次中包含正常类别样本 (结果标签为 0 的样本 150 条) 和随机抽取的非正常类别样本 (结果标签为 1 的样本 150 条), 由于分正常类别样本较少, 可以对非正常类别样本重复取样, 如此反复进行训练。

在 Representation Learning 层中, 基于深度学习模型的特征学习模块的结构如图 2 所示, 相关参数如表 2 所示, 输入空间为  $X_{A_1}$  (如 4.1.1 章节所示), 最终模块输出  $e_1 \in R^{n \times 6}$ 。基于知识库规则的特征学习模块  $g_2$  使用基于温度、烟雾传感器的模糊逻辑系统<sup>[9]</sup>, 输入为  $X_{A_2}$  (如 4.1.1 章节所示), 最终模块输出  $e_2 \in R^{n \times 1}$ , 即  $e_2 \in \{0, 1\}$ 。串联  $e_1$ 、 $e_2$ , Representation Learning 层最终输出  $E \in R^{n \times 7}$ 。

在 Forest Learning 层中, 模型根据 Representation Learning 层的输入数据最终做出决策, Forest Learning 层结构如 3 所示。

表 2. 基于深度学习模型的特征学习模块结构

Name	Conv #1	Conv #2	Conv #3	Pooling #1	Conv #4	Conv #5	Conv #6
Size	1×1	1×1	1×1	3×3	3×3	5×5	1×1
Stride	1	1	1	1	3	3	3
channel	3	3	3	3	6	6	6

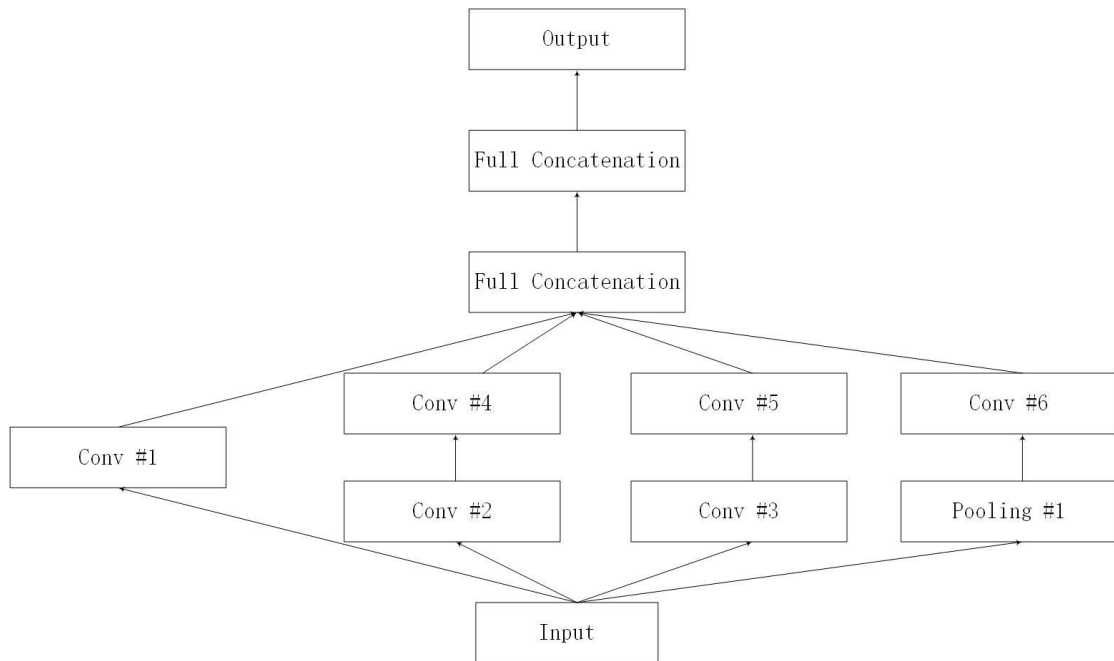


图 2. 基于深度学习模型的特征学习模块结构图

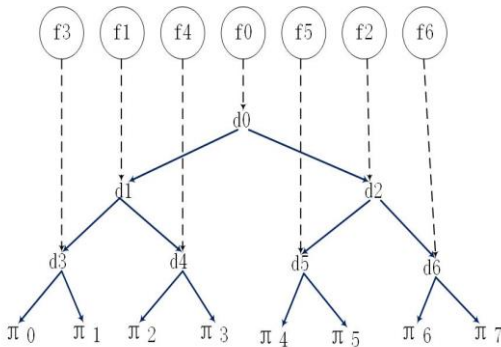


图 3. Forest Learning 层结构图

Model Report  
Accuracy: 0.9  
test-auc-mean and test-auc-std and train-auc-mean and train-auc-std:  
test-merror-mean 0.1  
test-error-std 0.044721  
Name: 82, dtype: float64 Accuracy: 0.9

图 4. 模型生成报告图

最终模型生成报告如图 4 所示。根据模型生成报告，模型在测试集上预测精度为 0.9，测试集上平均误差为 0.1，测试误差的标准偏差为 0.044721。

模型评估报告如表 3 所示，其中 Recall 和 F1 的计算中，0 代表 positive（正常），1 代表 negative（非正常）。表 3 中 Errors on TrainSet 表示模型在用于模型拟合的训练集中的准确率，Top-3 Errors on CV 表示模型基于 5 折交叉验证对于测试集的预测准确率最高的前三个结果，recall、f1 以基于 5 折交叉验证对于测试集的预测准确率最好的结果为标准，分别计算本文方法、BP 神经网络、随机森林以及支持向量机在数据集上的表现。由表 3 可得：(1) 无论是本文方法、BP 神经网络、随机森林或支持向量机，模型总是在训练集上拟合效果最好，模型都偏于过拟合。(2) 本文方法相对于 BP 神经网络、随机森林或支持向量机，在训练集和交叉验证的测试集上表现都更好，且组合模型在交叉验证的测试集上的误差的标准差为 0.804%，模型表现较为稳定且良好。(3) 本文方法相对于 BP 神经网络、随机森林或支持向量机，在测试集上较好的表现并没有在 recall 中体现出来，由 recall 值的定义可知本文方法对异常情况（positive）更加敏感。

表 3. 模型评估报告

模型名称	Errors on TrainSet		Top-3 Errors on CV		Recall	F1
深度集成模型(本文方法)	5.2	8.9	9.4	10.8	0.9	0.947
BP 神经网络	2.8	16.7	17.5	17.6	0.92	0.911
随机森林	6.4	10.4	10.6	11.3	0.92	0.902
SVM	16.8	15.4	16.7	16.8	0.8	0.842

## 5. 结论

根据基于知识库规则的预警系统和基于机器学习方法的预警系统各自优缺点，本文结合知识库规则和深度学习算法的优势，将基于知识库规则提取特征集合与基于深度学习模型提取的特征集合结合建立火灾事故预警系统。此方法根据传感器数据、建筑的致灾因子和损失控制因子提取特征，结合知识库提取的特征集合，代入一种集成神经森林模型

学习，使用一种全局优化方法完成参数优化，为建筑物提供火灾事故预警。实验表明本方法对火灾事故预警提供了一种解决方案，与其他单一的基于知识库规则的预警系统和基于机器学习方法的预警系统方法相比有更好的预警效果。

本文中 Forest Learning 层结构根据决策树训练结果进行初始化并固定其结构，之后的工作会寻求一种方法优化 Forest Learning 层结构以在不损

失模型预测精度的情况下降低模型计算成本。未来可以结合时间序列这一关键因素提取各类信息在时间维度上的特征,将分析结果作为新的特征加入火灾预警模型,进一步提升模型预测精度。

## 参考文献

- [1] Schmidhuber J. Deep Learning in neural networks: An overview. [J]. Neural Netw, 2015, 61:85-117.
- [2] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[C]// International Conference on Neural Information Processing Systems. Curran Associates Inc. 2012:1097-1105.
- [3] Mikolov T, Karafiát M, Burget L, et al. Recurrent neural network based language model[C]// INTERSPEECH 2010, Conference of the International Speech Communication Association, Makuhari, Chiba, Japan, September. DBLP, 2010:1045-1048.
- [4] Jerome H. Friedman. Greedy Function Approximation: A Gradient Boosting Machine[J]. The Annals of Statistics, 2001, 29(5):1189-1232.
- [5] Ho T K. Random Decision Forests[J]. Icdar, 1995, 1:278-282 vol. 1.
- [6] Shuangzhong Zheng, Yunfeng Deng, Qinghua Jiang. City fire risk assessment based on statistics data. [J] China Occupational Safety and Health Management System Certification, 2005, 1(3):15-18. 郑双忠, 邓云峰, 蒋清华. 基于火灾统计灾情数据的城市火灾风险分析[J]. 中国安全生产科学技术, 2005, 1(3):15-18.
- [7] Xuelin Zhang, Zhiyou Sun, Jinhui Wang. Applying Markov Chain to Forecast the Scale of Cities Fire[J]. Fire Safety Science, 2006, 15(3):168-171. 张学林, 孙志友, 汪金辉, 等. 基于马尔可夫链的城市火灾预测[J]. 火灾科学, 2006, 15(3):168-171.
- [8] Zhide Liu. Research and application of city fire alarm intelligent monitoring terminal[D]. Guangdong University of Technology, 2013. 刘德志. 城市火灾报警智能监控终端的研究与应用[D]. 广东工业大学, 2013.
- [9] Sharma D, Singh K, Aggarwal S. Implementation of Artificial Neural Fuzzy Inference System in a Real Time Fire Detection Mechanism[J]. International Journal of Computer Applications, 2016, 146(10).
- [10] Alamgir N, Boles W, Chandran V. A Model Integrating Conflagration prediction and Detection for Rural-Urban Interface[C]// International Conference on Digital Image Computing: Techniques and Applications. IEEE, 2016:1-8.
- [11] Gao D, Lin H, Jiang A, et al. A forest conflagration prediction system based on rechargeable wireless sensor networks[C]// IEEE International Conference on Network Infrastructure and Digital Content. IEEE, 2015:405-408.
- [12] Wang X, Wotton B M, Cantin A S, et al. cffdrs: an R package for the Canadian Forest Fire Danger Rating System[J]. Ecological Processes, 2017, 6(1):5.
- [13] Oliveira A, Nero M. Application of Fuzzy Logic in Prediction of Fire in João Pessoa City - Brazil[M]// Geo-Informatics in Resource Management and Sustainable Ecosystem. Springer Berlin Heidelberg, 2013:323-334.
- [14] Richmond D L, Kainmueller D, Yang M, et al. Mapping stacked decision forests to deep and sparse convolutional neural networks for semantic segmentation[C]//Proc. British Machine Vision Conference. 2015.
- [15] Kotschieder P, Fiterau M, Criminisi A, et al. Deep Neural Decision Forests[C]// IEEE International Conference on Computer Vision. IEEE, 2016:1467-1475.
- [16] Zhou Z H, Feng J. Deep Forest: Towards An Alternative to Deep Neural Networks[J]. 2017.
- [17] Suarez A, Lutsko J F. Globally optimal fuzzy decision trees for classification and regression[J]. Pattern Analysis & Machine Intelligence IEEE Transactions on, 1999, 21(12):1297-1311.
- [18] Kiwiel K C. Convergence and efficiency of subgradient methods for quasiconvex minimization[J]. Mathematical Programming, 2001, 90(1):1-25.
- [19] Szegedy C, Liu W, Jia Y, et al. Going deeper with convolutions[C]. Cvpr, 2015.
- [20] Taylor S W, Alexander M E. Field guide to the Canadian Forest Fire Behavior Prediction (FBP) System. (BINDER) [M]. 2016.
- [21] Aiyu Wu, Shiliang Shi, Conglu Wang. The Model for Risk Evaluation of Urban Fire Based on Neural Network and Genetic Algorithms[J]. China Safety Science Journal, 2006, 16(11):108-113. 伍爱友, 施式亮, 王从陆. 基于神经网络和遗传算法的城市火灾风险评价模型[J]. 中国安全科学学报, 2006, 16(11):108-113.
- [22] Zheng Fang, Juanjuan Chen, Tao Xie. Fire Risk Assessment of Malls Based on the Cluster Analysis and AHP[J]. Journal of Northeastern University(Natural Science), 2015, 36(3):442-447. 方正, 陈娟娟, 谢涛, 等.

基于聚类分析和 AHP 的商场类建筑火灾风险评估[J]. 东北大学学报(自然科学版), 2015, 36(3):442-447.

[23] Yang L, Dawson C W, Brown M R, et al. Neural network and GA approaches for dwelling fire occurrence

prediction[J]. Knowledge-Based Systems, 2006, 19(4):213-219.